

THÔNG TIN CHUNG CỦA NHÓM

- Link YouTube

<https://youtu.be/mSvGdMiopVc>

- Link slides

<https://github.com/namnguyenuit/CS2205.JAN2026/blob/main/Nam%20Nguy%E1%BB%85n%20Ng%E1%BB%8Dc%20-%20CS2205.JAN2026.DeCuong.FinalReport.Template.Slide.pdf>

- Họ và Tên: Nguyễn Ngọc

Nam

- MSHV: 250101094



- Lớp: CS2205.JAN2026

- Tự đánh giá (điểm tổng kết môn): 10/10

- Số buổi vắng: 0

- Số câu hỏi QT cá nhân: 3

- Số câu hỏi QT của cả nhóm: 15

- Link Github:

<https://github.com/namnguyenuit/CS2205.JAN2026>

ĐỀ CƯƠNG NGHIÊN CỨU

TÊN ĐỀ TÀI (IN HOA)

NÂNG CAO KHẢ NĂNG SUY LUẬN KHÔNG GIAN CỦA MÔ HÌNH NGÔN NGỮ - THỊ GIÁC TRÊN KỆ HÀNG BÁN LẺ THÔNG QUA ĐỒ THỊ NGỮ CẢNH

TÊN ĐỀ TÀI TIẾNG ANH (IN HOA)

ENHANCING SPATIAL REASONING OF VISION-LANGUAGE MODELS ON RETAIL SHELVES VIA SCENE GRAPH

TÓM TẮT

Theo dõi kệ hàng là bài toán cần thiết trong các chuỗi bán lẻ hiện nay, nhưng vẫn phụ thuộc nhiều vào quan sát thủ công. Nhân viên phải kiểm tra sản phẩm còn hàng, khu vực trống và vị trí sản phẩm trên kệ. Công việc này tốn thời gian, dễ sai sót, đặc biệt với các kệ có mật độ sản phẩm cao hoặc nhiều mặt hàng tương đồng về bao bì. Người mua cũng mất thời gian khi tìm sản phẩm hoặc kiểm tra sản phẩm còn hàng hay không. Các phương pháp thị giác máy tính đã hỗ trợ phát hiện và đếm sản phẩm, nhưng phần lớn vẫn dừng ở bounding box, nhãn hoặc số lượng.

Nghiên cứu này hướng đến bài toán hiểu không gian trong ảnh kệ hàng bán lẻ, gồm phát hiện sản phẩm, mô tả quan hệ vị trí và trả lời câu hỏi bằng ngôn ngữ tự nhiên. Phương pháp đề xuất gồm hai phần. Thứ nhất, ảnh sản phẩm được đưa qua DINOv2[1] để trích xuất đặc trưng thị giác, sau đó được lưu vào cơ sở dữ liệu vector kèm metadata như tên sản phẩm, màu sắc, hình dạng và kiểu bao bì... Khi có sản phẩm mới, hệ thống chỉ cần bổ sung ảnh mẫu và metadata tương ứng, không cần huấn luyện lại mô hình. Thứ hai, với ảnh kệ hàng đầu vào, Grounding DINO[2] được dùng để phát hiện vùng sản phẩm. Mỗi vùng được cắt ra, trích xuất vector bằng DINOv2[1] và so khớp với cơ sở dữ liệu vector bằng cosine similarity[3]. Kết quả truy xuất, metadata và tọa độ bounding box được dùng để gom nhóm sản phẩm, xây dựng Scene Graph và hỗ trợ VLM trả lời câu hỏi. Thực nghiệm dự kiến sử dụng bộ dữ liệu


SKU-110K[4], với tập xây dựng cơ sở dữ liệu và tập đánh giá được tách riêng nhằm tránh rò rỉ dữ liệu. Scene Graph được dùng làm biểu diễn trung gian nhằm giảm hạn chế của VLM trong đếm, định vị và suy luận không gian[5][6].

GIỚI THIỆU

1. Xác định bài toán

Bài toán của đề tài được xác định là xây dựng một hướng xử lý ảnh kệ hàng nhằm hỗ trợ người dùng đặt câu hỏi bằng ngôn ngữ tự nhiên, giúp tiết kiệm thời gian trong việc tìm kiếm sản phẩm tại cửa hàng.

- + Đầu vào: một ảnh kệ hàng và một câu hỏi. Ví dụ như hỏi vị trí sản phẩm, số lượng sản phẩm/cụm sản phẩm, quan hệ trái/phải/trên/dưới hoặc khu vực có dấu hiệu trống.
- + Đầu ra: câu trả lời bằng ngôn ngữ tự nhiên.



Hình 1. Mô tả bài toán

2. Tình hình nghiên cứu hiện nay

Các nghiên cứu về kệ hàng bán lẻ hiện nay chủ yếu tập trung vào phát hiện, nhận diện và đếm sản phẩm, với đầu ra thường là bounding box, nhãn lớp hoặc số lượng. Tuy nhiên, khả năng trả lời câu hỏi bằng ngôn ngữ tự nhiên về quan

hệ vị trí giữa các sản phẩm vẫn chưa được khai thác nhiều. Bên cạnh đó, các phương pháp học giám sát đòi hỏi dữ liệu gán nhãn chi tiết, trong khi việc annotation cho nhiều sản phẩm nhỏ, giống nhau và xếp sát nhau trên kệ rất tốn thời gian. Gần đây, VLM mở ra hướng xử lý linh hoạt hơn, nhưng các nghiên cứu về spatial reasoning cho thấy mô hình này vẫn chưa ổn định khi đếm, định vị hoặc so sánh vị trí đối tượng trực tiếp từ ảnh thô [5][6]. Vì vậy, việc kết hợp xử lý ảnh và Scene Graph là cần thiết để hỗ trợ VLM suy luận vị trí sản phẩm trên kệ hàng hiệu quả hơn.

3. Tính mới của đề tài

Đề tài không xem kệ hàng là bài toán detect mà xem đó là bài toán hiểu không gian bằng Scene Graph. VLM được dùng ở tầng suy luận và diễn đạt, trong khi các quan hệ hình học được chuẩn hóa bằng Scene Graph để giảm lỗi suy luận không gian. Điểm bổ sung của đề tài là kết hợp DINOv2[1] và cơ sở dữ liệu vector để truy hồi thông tin sản phẩm từ ảnh tham chiếu, giúp giảm phụ thuộc vào tập nhãn SKU cố định và tăng khả năng mở rộng khi có sản phẩm mới.

MỤC TIÊU

1. Xây dựng hướng tiếp cận hiểu kệ hàng bằng ngôn ngữ:

Đề tài hướng đến việc xây dựng một pipeline cho phép người dùng đặt câu hỏi bằng ngôn ngữ tự nhiên trên ảnh kệ hàng, thay vì chỉ nhận đầu ra là nhãn lớp hoặc bounding box. Các câu hỏi tập trung vào vị trí sản phẩm, số lượng tương đối, quan hệ trái/phải/trên/dưới, sản phẩm nằm gần nhau và khu vực có dấu hiệu trống.

2. Giảm phụ thuộc vào dữ liệu gán nhãn cố định:

Đề tài khai thác DINOv2[1] để trích xuất đặc trưng thị giác từ từng vùng sản phẩm và sử dụng cơ sở dữ liệu vector để truy hồi sản phẩm tương đồng từ ảnh tham chiếu. Cách tiếp cận này không phụ thuộc vào một tập nhãn SKU cố định và có thể mở rộng sản phẩm mới bằng cách bổ sung ảnh tham chiếu vào vector database, thay vì phải gán nhãn lại dữ liệu và huấn luyện lại mô hình. Điều này

phù hợp với bối cảnh bán lẻ, nơi sản phẩm, bao bì và cách sắp xếp trên kệ thường xuyên thay đổi.

3. Kiểm chứng vai trò của Scene Graph trong việc suy luận không gian của VLM:

Đề tài đánh giá hiệu quả việc bổ sung Scene Graph giúp VLM trả lời ổn định hơn cho các câu hỏi liên quan đến không gian trên kệ hàng.


NỘI DUNG VÀ PHƯƠNG PHÁP

Quy trình nghiên cứu được tổ chức thành hai phần chính.

Phần 1. Xây dựng cơ sở dữ liệu vector sản phẩm

Phần này được thực hiện trước giai đoạn suy luận. Đề tài sử dụng một tập ảnh tham chiếu tách riêng khỏi tập đánh giá. Mỗi ảnh tham chiếu được trích xuất đặc trưng bằng DINOv2[1], chuẩn hóa vector và lưu vào vector database cùng metadata mô tả mức, tên sản phẩm, loại sản phẩm, màu sắc, hình dạng hoặc kiểu bao bì... Nếu SKU-110K[4] không cung cấp đầy đủ nhãn, metadata sẽ được bổ sung thủ công trên một tập con nhỏ, chỉ dùng cho vector database và đánh giá truy hồi, không dùng để huấn luyện lại mô hình.

Khi cần bổ sung sản phẩm mới, hệ thống chỉ thêm ảnh tham chiếu và metadata tương ứng vào cơ sở dữ liệu vector. Khi truy vấn, vector của crop sản phẩm được so khớp với vector trong database bằng cosine similarity[3].




Hình 2. Hình mô tả quá trình chuẩn bị dữ liệu tham chiếu trong vector database

Phần 2. Xử lý ảnh kệ hàng và suy luận không gian

Stage	Thành phần	Input	Output	Vai trò
1	Detector (Grounding DINO[2])	Ảnh + prompt	Bounding box	Phát hiện sản phẩm/cụm theo prompt
2	DINOv2[1] + vector database	Crop từ bounding box	Top-K sản phẩm tương đồng + điểm similarity	Truy hồi sản phẩm gần giống từ vector database tham chiếu
3	Ghép thông tin	Bounding Box + metadata truy hồi	Node sản phẩm	Gắn metadata vào đúng vùng, gom nhóm cùng loại và cùng tầng kệ
4	Scene graph(Ow-SGG[7]/PGSG[8] /rule-base)	Node + tọa độ	Edge không gian	Biểu diễn trái/phải/trên/dưới/gần nhau/rõng
5	VLM reasoning (Qwen2.5-VL, InternVL, LLaVA)	Ảnh + graph + prompt	Câu trả lời	Suy luận bằng scene grap, giảm đoán mò

Bảng 1. Các stage cho quá trình suy luận không gian cho kệ hàng



Hình 3. Mô tả biểu diễn đồ thị ngữ cảnh Scene Graph

Phương pháp đánh giá

Với SKU-110K[4], annotation bounding box có sẵn chỉ được dùng để so sánh với bounding box do detector tạo ra. Các phần chưa có sẵn như metadata truy hồi, quan hệ không gian, Scene Graph, câu hỏi và câu trả lời sẽ được gán nhãn bổ sung trên một tập con để đo lỗi.

Thành phần	Chỉ số đo lỗi
Grounding DINO[2]	AP50/AP75, Precision, Recall
DINOv2[1] + vector database	Top-1 Accuracy, Top-5 Accuracy, Recall@K, mAP, Similarity threshold analysis
Scene Graph	Recall@K, Mean Recall@K[9]
VLM reasoning	Accuracy, F1

Bảng 2. Các chỉ số đánh giá cho các thành phần trong pipeline

Phương pháp thực nghiệm

Phần thực nghiệm cũng được tách thành hai phần. Với phần thứ nhất, đề tài đánh giá chất lượng truy hồi của DINOv2 + vector database thông qua Top-K, ngưỡng similarity và khả năng gán metadata đúng cho crop sản phẩm. Với phần thứ hai, đề tài đánh giá toàn pipeline từ phát hiện bounding box đến tạo Scene Graph và VLM reasoning. Ngoài ra, ablation được dùng để kiểm tra khi thêm bounding box, truy hồi thị giác và Scene Graph thì câu trả lời của VLM có cải thiện hay không.

Bounding Box	Visual Retrieval	Scene Graph	VLM	Câu hỏi kiểm tra
-	-	-	Có	VLM có phát hiện và suy luận tốt không?
Có	-	-	Có	Bounding box có giúp VLM phát hiện sản phẩm tốt hơn không?
Có	Có	-	Có	DINOv2 + vector database có giúp phân biệt sản phẩm và gom nhóm tốt hơn không?

Có	Có	Có	Có	Scene Graph có giúp suy luận tốt hơn không?
----	----	----	----	---

Bảng 3. Ablation cho quá trình thực nghiệm

KẾT QUẢ MONG ĐỢI

1. Cải thiện độ chính xác trả lời câu hỏi không gian

Pipeline đề xuất được kỳ vọng giúp tăng độ chính xác trong việc trả lời các câu hỏi liên quan đến vị trí, số lượng và quan hệ không gian giữa các sản phẩm so với cách đưa ảnh thô trực tiếp vào VLM. Đặc biệt, hệ thống kỳ vọng hoạt động tốt hơn ở các câu hỏi như sản phẩm nằm ở tầng nào, sản phẩm nào ở bên trái hoặc bên phải, có bao nhiêu sản phẩm cùng loại và khu vực nào có dấu hiệu trống.

2. Cải thiện khả năng tìm kiếm sản phẩm

Việc sử dụng DINOv2 kết hợp vector database được kỳ vọng giúp tăng khả năng tìm kiếm đúng sản phẩm hoặc nhóm sản phẩm tương đồng trong Top-K kết quả. Kết quả này giúp hệ thống có thêm thông tin thị giác ổn định hơn trước khi thực hiện suy luận không gian.

3. Giảm lỗi suy luận trực tiếp từ ảnh thô

So với cấu hình VLM-only, pipeline có bổ sung bounding box, visual retrieval và Scene Graph được kỳ vọng sẽ giảm các lỗi thường gặp của VLM như đếm sai sản phẩm, nhầm vị trí trái/phải/trên/dưới hoặc bỏ sót các sản phẩm nhỏ trên kệ.

4. Chứng minh vai trò của từng thành phần trong pipeline

Thông qua ablation study, đề tài kỳ vọng sẽ cho thấy hiệu quả tăng dần qua các cấu hình: VLM-only, VLM + bounding box, VLM + bounding box + visual retrieval và VLM + bounding box + visual retrieval + Scene Graph. Trong đó, cấu hình đầy đủ được kỳ vọng đạt kết quả tốt nhất trên bộ câu hỏi kiểm thử.

5. Xác định nguồn lỗi trong toàn pipeline

Bảng đánh giá theo từng stage được kỳ vọng sẽ giúp xác định lỗi chủ yếu phát sinh ở bước nào, gồm phát hiện bounding box, truy hồi thị giác, gom nhóm sản phẩm, xây dựng Scene Graph hoặc sinh câu trả lời bằng VLM. Điều này giúp việc phân tích kết quả rõ ràng hơn thay vì chỉ đánh giá đúng hoặc sai ở câu trả lời cuối cùng.

TÀI LIỆU THAM KHẢO

- [1] Maxime Oquab, Timothée Darcet, Théo Moutakanni, Huy V. Vo, Marc Szafraniec, Vasil Khalidov, Pierre Fernandez, Daniel Haziza, Francisco Massa, Alaaeldin El-Nouby, Mido Assran, Nicolas Ballas, Wojciech Galuba, Russell Howes, Po-Yao Huang, Shang-Wen Li, Ishan Misra, Michael Rabbat, Vasu Sharma, Gabriel Synnaeve, Hu Xu, Hervé Jégou, Julien Mairal, Patrick Labatut, Armand Joulin, Piotr Bojanowski: DINOv2: Learning Robust Visual Features without Supervision. Trans. Mach. Learn. Res. 2024 (2024)
- [2] Shilong Liu, Zhaoyang Zeng, Tianhe Ren, Feng Li, Hao Zhang, Jie Yang, Qing Jiang, Chunyuan Li, Jianwei Yang, Hang Su, Jun Zhu, Lei Zhang: Grounding DINO: Marrying DINO with Grounded Pre-training for Open-Set Object Detection. ECCV (47) 2024: 38-55
- [3] Jeff Johnson, Matthijs Douze, Herve Jegou: Billion-scale similarity search with GPUs. IEEE Trans. Big Data 7(3): 535-547 (2021)
- [4]. Eran Goldman, Roei Herzig, Aviv Eisenschat, Jacob Goldberger, Tal Hassner: Precise Detection in Densely Packed Scenes. CVPR 2019: 5227-5236
- [5] Atin Pothiraj, Elias Stengel-Eskin, Jaemin Cho, Mohit Bansal: CAPTURE: Evaluating Spatial Reasoning in Vision Language Models via Occluded Object Counting. ICCV 2025: 8001-8010
- [6] Ilias Stogiannidis, Steven McDonagh, Sotirios A. Tsafaris: Mind the Gap: Benchmarking Spatial Reasoning in Vision-Language Models. CoRR abs/2503.19707 (2025)
- [7] Amartya Dutta, Kazi Sajeed Mehrab, Medha Sawhney, Abhilash Neog, Mridul Khurana, Sepideh Fatemi, Aanish Pradhan, M. Maruf, Ismini Lourentzou, Arka Daw, Anuj Karpatne: Open World Scene Graph Generation using Vision Language Models. CV in the Wild Workshop, CVPR 2025. CoRR abs/2506.08189 (2025)
- [8] Rongjie Li, Songyang Zhang, Dahua Lin, Kai Chen, Xuming He: From Pixels to Graphs: Open-Vocabulary Scene Graph Generation with Vision-Language Models. CVPR 2024: 28076-28086

- [9] Julian Lorenz, Robin Schön, Katja Ludwig, Rainer Lienhart: A Review and Efficient Implementation of Scene Graph Generation Metrics. CVPR Workshops 2024: 2567-2575
- [10] Zuoxu Wang, Zhijie Yan, Shufei Li, Jihong Liu: IndVisSGG: VLM-based scene graph generation for industrial spatial intelligence. Adv. Eng. Informatics 65: 103107 (2025)