

NÂNG CAO KHẢ NĂNG SUY LUẬN KHÔNG GIAN CỦA MÔ HÌNH NGÔN NGỮ - THỊ GIÁC TRÊN KỆ HÀNG BÁN LẺ THÔNG QUA ĐỒ THỊ NGỮ CẢNH

Nguyễn Ngọc Nam - 250101094

CS2205.JAN2026

GVHD: PGS.TS.LÊ ĐÌNH DUY

Tóm tắt

- Lớp: CS2205.JAN2026
- Link Github:

<https://github.com/namnguyenuit/CS2205.JAN2026>

- Link YouTube video:

<https://youtu.be/mSvGdMiopVc>



Nguyễn Ngọc Nam
250101094

Giới thiệu

Bài toán nghiên cứu

- Đầu vào: ảnh kệ hàng + câu hỏi tự nhiên.
- Đầu ra: câu trả lời về vị trí, số lượng, quan hệ hoặc vùng trống.

Khoảng trống nghiên cứu

- Nhiều hướng hiện tại dừng ở bounding box, nhãn hoặc số lượng.
- VLM còn chưa ổn định khi đếm, định vị và so sánh vị trí trực tiếp từ ảnh thô.

The screenshot displays a research interface for a Visual Question Answering (VQA) system. It is divided into three main sections:

- ẢNH KỆ HÀNG (Shelf Image):** A photograph of a supermarket shelf with six levels. The levels are labeled on the left: TẦNG 6 (purple), TẦNG 5 (blue), TẦNG 4 (green), TẦNG 3 (yellow), TẦNG 2 (orange), and TẦNG 1 (red). The TẦNG 4 shelf is highlighted with a green border and labeled "NƯỚC CAM" (Orange Juice) in a green box.
- HỎI ĐÁP (Q&A):** A chat interface showing a series of user questions and system answers.
 - User: "Nước cam nằm ở tầng mấy?" (Where is the orange juice?)
System: "Nước cam nằm ở **tầng 4**." (Orange juice is on **floor 4**.)
 - User: "Có bao nhiêu loại nước cam trên kệ?" (How many types of orange juice are on the shelf?)
System: "Có **4** loại nhiều cam khác nhau trên kệ **tầng 4**." (There are **4** types of many oranges on the shelf **floor 4**.)
 - User: "Nước cam nằm giữa những sản phẩm nào?" (Where is the orange juice among the products?)
System: "Nước cam nằm giữa **sữa trái cây** (bên trái) và **trà đóng chai** (bên phải)." (Orange juice is between **fruit milk** (left) and **bottled tea** (right).)
 - User: "Khu vực nào trên kệ đang trống?" (Which area on the shelf is empty?)
System: "Hiện tại không có khu vực trống rõ rệt trên các tầng kệ." (Currently, there is no clearly empty area on the shelves.)
- THÔNG TIN TỔNG QUAN (Summary Information):** A summary bar at the bottom showing statistics:
 - 6 Tầng kệ (Shelves)
 - 128 Sản phẩm (Products)
 - 23 Loại sản phẩm (Product types)
 - Không có Khu vực trống lớn (No large empty area)

Minh họa bài toán: ảnh kệ hàng + hỏi đáp vị trí sản phẩm

Mục tiêu

1

Hiểu kệ hàng bằng ngôn ngữ

Cho phép hỏi đáp tự nhiên thay vì chỉ xuất nhãn lớp hoặc bounding box.

2

Giảm phụ thuộc nhãn cố định

Dùng DINOv2 + vector database để truy hồi sản phẩm từ ảnh tham chiếu.


3

Kiểm chứng vai trò Scene Graph

Đánh giá liệu Scene Graph giúp VLM suy luận không gian ổn định hơn.

Nội dung và Phương pháp - Phần 1

Xây dựng cơ sở dữ liệu vector sản phẩm từ ảnh tham chiếu



Chuẩn bị dữ liệu tham chiếu trong vector database

Truy vấn: crop → DINOv2 → cosine similarity → top-K tương đồng

Đầu ra phần 1: vector database + metadata sản phẩm để phục vụ truy hồi ở giai đoạn suy luận.

Nội dung và Phương pháp - Phần 2

Xử lý ảnh kệ hàng, tạo Scene Graph và hỗ trợ VLM trả lời câu hỏi

1

Grounding DINO

Ảnh + prompt $\rightarrow$ bounding box sản phẩm/cụm sản phẩm.

2

DINOv2 + vector DB

Crop $\rightarrow$ top-K sản phẩm tương đồng + similarity.

3



Ghép thông tin

Gắn metadata và gom nhóm cùng loại/cùng tầng kệ.

4

Scene Graph + VLM

Quan hệ không gian $\rightarrow$ VLM suy luận và diễn đạt.



Scene Graph biểu diễn quan hệ không gian

Đầu vào: ảnh kệ hàng + câu hỏi
Đầu ra: câu trả lời tự nhiên về vị trí, số lượng hoặc vùng trống

Đánh giá và thực nghiệm

Dữ liệu: SKU-110K

Ablation chính

A0 VLM only

A1 + Bounding box

A2 + Visual retrieval

A3 + Scene Graph

Chỉ số đánh giá

Detector

AP50/AP75, Precision, Recall

Retrieval

Top-1 / Top-5, Recall@K, mAP

Scene Graph

Recall@K, Mean Recall@K

VLM

Accuracy, F1

Ý nghĩa thực nghiệm

- Đánh giá riêng phần và toàn pipeline
- Kiểm tra tác động của bounding box, visual retrieval và Scene Graph lên câu trả lời cuối cùng.

Kết quả mong đợi

1

Cải thiện độ chính xác trả lời câu hỏi không gian

- Tốt hơn cách đưa ảnh thô trực tiếp vào VLM.
- Tập trung vào vị trí, số lượng và quan hệ giữa sản phẩm.
- Câu hỏi mục tiêu: tầng kệ, trái/phải, số lượng cùng loại, vùng trống.

2

Cải thiện tìm kiếm sản phẩm

Tăng Top-K đúng sản phẩm hoặc nhóm tương đồng.

3

Giảm lỗi từ ảnh thô

Giảm đếm sai, nhầm trái/phải/trên/dưới, bỏ sót sản phẩm nhỏ.

4

Chứng minh vai trò thành phần

Ablation cho thấy hiệu quả tăng dần qua từng cấu hình.

5

Xác định nguồn lỗi pipeline

Chỉ ra lỗi tại detector, retrieval, gom nhóm, Scene Graph hoặc VLM.

Tài liệu tham khảo

- [1] Maxime Oquab, Timothée Darcet, Théo Moutakanni, Huy V. Vo, Marc Szafraniec, Vasil Khalidov, Pierre Fernandez, Daniel Haziza, Francisco Massa, Alaaeldin El-Nouby, Mido Assran, Nicolas Ballas, Wojciech Galuba, Russell Howes, Po-Yao Huang, Shang-Wen Li, Ishan Misra, Michael Rabbat, Vasu Sharma, Gabriel Synnaeve, Hu Xu, Hervé Jégou, Julien Mairal, Patrick Labatut, Armand Joulin, Piotr Bojanowski: DINOv2: Learning Robust Visual Features without Supervision. Trans. Mach. Learn. Res. 2024 (2024)
- [2] Shilong Liu, Zhaoyang Zeng, Tianhe Ren, Feng Li, Hao Zhang, Jie Yang, Qing Jiang, Chunyuan Li, Jianwei Yang, Hang Su, Jun Zhu, Lei Zhang: Grounding DINO: Marrying DINO with Grounded Pre-training for Open-Set Object Detection. ECCV (47) 2024: 38-55
- [3] Jeff Johnson, Matthijs Douze, Herve Jegou: Billion-scale similarity search with GPUs. IEEE Trans. Big Data 7(3): 535-547 (2021)
- [4]. Eran Goldman, Roei Herzig, Aviv Eisenschtat, Jacob Goldberger, Tal Hassner: Precise Detection in Densely Packed Scenes. CVPR 2019: 5227-5236
- [5] Atin Pothiraj, Elias Stengel-Eskin, Jaemin Cho, Mohit Bansal: CAPTURE: Evaluating Spatial Reasoning in Vision Language Models via Occluded Object Counting. ICCV 2025: 8001-8010
- [6] Ilias Stogiannidis, Steven McDonagh, Sotirios A. Tsaftaris: Mind the Gap: Benchmarking Spatial Reasoning in Vision-Language Models. CoRR abs/2503.19707 (2025)
- [7] Amartya Dutta, Kazi Sajeed Mehrab, Medha Sawhney, Abhilash Neog, Mridul Khurana, Sepideh Fatemi, Aanish Pradhan, M. Maruf, Ismini Lourentzou, Arka Daw, Anuj Karpatne: Open World Scene Graph Generation using Vision Language Models. CV in the Wild Workshop, CVPR 2025. CoRR abs/2506.08189 (2025)
- [8] Rongjie Li, Songyang Zhang, Dahua Lin, Kai Chen, Xuming He: From Pixels to Graphs: Open-Vocabulary Scene Graph Generation with Vision-Language Models. CVPR 2024: 28076-28086
- [9] Julian Lorenz, Robin Schön, Katja Ludwig, Rainer Lienhart: A Review and Efficient Implementation of Scene Graph Generation Metrics. CVPR Workshops 2024: 2567-2575
- [10] Zuoxu Wang, Zhijie Yan, Shufei Li, Jihong Liu: IndVisSGG: VLM-based scene graph generation for industrial spatial intelligence. Adv. Eng. Informatics 65: 103107 (2025)

Cảm ơn thầy và các bạn đã lắng nghe!